



(12) 发明专利申请

(10) 申请公布号 CN 121069407 A

(43) 申请公布日 2025. 12. 05

(21) 申请号 202511606088.6

G06V 10/82 (2022.01)

(22) 申请日 2025.11.05

G06T 7/246 (2017.01)

G06T 7/277 (2017.01)

(71) 申请人 中国矿业大学

地址 221000 江苏省徐州市铜山区大学路1号

(72) 发明人 李会军 刘昊华 叶宾 刘姜
姜明远 秦世良 尹倩(74) 专利代理机构 徐州智慧星专利商标代理
事务所(普通合伙) 32957

专利代理师 申纪文

(51) Int. Cl.

G01S 17/66 (2006.01)

G01S 7/48 (2006.01)

G06V 10/25 (2022.01)

G06V 10/80 (2022.01)

权利要求书5页 说明书13页 附图1页

(54) 发明名称

一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法

(57) 摘要

本发明公开了一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法,首先采集激光雷达点云数据,并对激光雷达点云数据进行空间建模和坐标变换的预处理;进行显著性筛选;基于距离分区驱动,进行Pillar构建与编码;构建深度学习检测网络;基于Anchor设计与匹配策略对融合后的特征中空弱目标进行尺寸适配;基于扩展卡尔曼滤波器EKF对目标状态进行时序预测与观测更新,完成对低慢小目标检测与轨迹的预测跟踪。本发明能够在保留激光雷达高精度优势的同时,提升其对弱反射、小体积、运动不规则目标的识别能力,并具备强鲁棒性与环境适应能力,从而实现对低慢小飞行目标的稳定、精准感知与持续跟踪。

采集激光雷达点云数据,并对激光雷达点云数据进行空间建模和坐标变换的预处理;



对预处理后的数据进行显著性筛选,得到筛选后的点云数据;



基于距离分区驱动,对筛选后的点云数据进行Pillar构建与编码,得到pillar表达向量;



构建深度学习检测网络,以pillar表达向量作为输入,输出融合后的特征;



基于Anchor设计与匹配策略对融合后的特征中空弱目标进行尺寸适配;



基于扩展卡尔曼滤波器EKF对目标状态进行时序预测与观测更新,完成对低慢小目标检测与轨迹的预测跟踪。

1. 一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法, 其特征在于, 包括如下步骤:

步骤1、采集激光雷达点云数据, 并对激光雷达点云数据进行空间建模和坐标变换的预处理;

步骤2、对预处理后的数据进行显著性筛选, 得到筛选后的点云数据;

步骤3、基于距离分区驱动, 对筛选后的点云数据进行Pillar构建与编码, 得到pillar表达向量;

步骤4、构建深度学习检测网络, 以pillar表达向量作为输入, 输出融合后的特征;

步骤5、基于Anchor设计与匹配策略对融合后的特征中空中弱目标进行尺寸适配;

步骤6、基于扩展卡尔曼滤波器EKF对目标状态进行时序预测与观测更新, 完成对低慢小目标检测与轨迹的预测跟踪。

2. 根据权利要求1所述的一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法, 其特征在于, 步骤1具体为: 测量雷达从安装基准面至传感器底部的垂直高度 H_0 , 记录雷达初始安装时的俯仰角 θ 、水平旋转偏转 ψ , 以及雷达相对于载体坐标系原点的水平位置偏移量 $\Delta x, \Delta y$, 将数据输入标定模块, 构建雷达传感器在平台坐标系下的外参矩阵 T_{ext} ; 在点云采集过程中, 每一帧原始点云数据以局部坐标形式表示为:

$$P^{raw} = \{P_i = (x_i, y_i, z_i, I_i)\}_{i=1}^N,$$

其中, P^{raw} 为每一帧点云的原始数据, x, y, z 为每个点云在局部坐标系下的横坐标, 纵坐标以及高度信息, I 为每个点云的反射强度, N 为每帧原始点云数据中点云的数量;

读取外参 T_{ext} , 并对每个点执行坐标变换:

$$P_i^{abs} = T_{ext} \cdot \begin{bmatrix} x_i \\ y_i \\ z_i \\ 1 \end{bmatrix},$$

变换后得到点在平台全局空间下的位置 $(x_i^{abs}, y_i^{abs}, z_i^{abs})$;

计算点相对于地面的垂直高度信息:

$$h_i = z_i^{abs} - H_0,$$

对每个点计算其空间距离:

$$d_i = \sqrt{(x_i)^2 + (y_i)^2 + (z_i)^2},$$

根据经验设定的阈值 D_1, D_2 , 将点云划分为三个空间区域:

$$Region(P_i) = \begin{cases} \text{Near Field}, & d_i \leq D_1 \\ \text{Mid Field}, & D_1 < d_i \leq D_2, \\ \text{Far Field}, & d_i > D_2 \end{cases}$$

其中, $Region$ 为点云的空间区域, D_1, D_2 为根据经验设定的点云近距离, 中距离以及远

距离的阈值界限。

3. 根据权利要求1所述的一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法, 其特征在于, 步骤2具体为:

每帧点云采集完成后, 扫描所有点的反射强度值, 提取该帧的最大值 $I_{\max}$ 与最小值 $I_{\min}$, 对每个点的反射强度 I_i 进行归一化:

$$\tilde{I}_i = \frac{I_i - I_{\min}}{I_{\max} - I_{\min}},$$

采用KD-Tree邻域搜索在每个点的三维邻域内统计邻域点数量 $N_r(i)$:

$$N_r(i) = |\{P_j \in P \mid \|P_j - P_i\|_2 < r\}|,$$

其中, P_i 为当前正在计算显著性的目标点, P_j 为点云 P 中的其他任意点;

将邻域点数归一化:

$$\tilde{N}_i = \frac{N_r(i)}{\max_j N_r(j)},$$

其中, $\tilde{N}_i$ 为归一化局部密度值, $\max_j N_r(j)$ 为当前帧点云中所有点的局部密度值的最大值;

在两个维度的归一化之后, 为每个点构建显著性评分 S_i :

$$S_i = \lambda_1 \cdot \tilde{I}_i + \lambda_2 \cdot \tilde{N}_i,$$

其中, $\lambda_1 + \lambda_2 = 1$; 引入自适应权重调整机制: 在运行时, 当某点属于Far Field区域时, 上调 λ_1 权重, 同时降低显著性阈值 T_s ;

$$\lambda_1^{far} = \lambda_1 + \Delta_\lambda, T_s^{far} = T_s - \Delta_T,$$

其中, Δ_λ 和 Δ_T 表示动态基础阈值系数, T_s^{far} 表示点云处于Far Field区域的显著性阈值;

最终, 依据阈值判断是否保留该点进入后续pillar构建:

$$\text{Retain}(P_i) = \begin{cases} 1, & S_i \geq T_s \\ 0, & S_i < T_s \end{cases}.$$

4. 根据权利要求1所述的一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法, 其特征在于, 步骤3具体为: 读取pillar参数表, 采用栅格索引法进行pillar划分, 按所选区域内的 $(\Delta x, \Delta y)$ 网格划分BEV空间;

每个格点对应一个pillar柱体, 将筛选保留的点云投影至BEV网格, 标记所属pillar编号, 若某pillar内点数 $\geq$ 该区域内对应 $n_{\min}$, 则视为合法pillar, 进入下一阶段编码, 其余点云剔除; 对每个合法pillar内的点 $\{p_j\}_{j=1}^n$, 计算点与pillar内质心的偏移量和点与pillar中心网格位置的偏移量后进行特征向量拼接, 通过共享MLP对每个点特征进行升维编码, 随后在pillar维度做最大池化, 形成定长的pillar表达向量。

5. 根据权利要求1所述的一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法, 其特征在于, 步骤4具体为: 在主干网络的浅层与中层特征输出中, 引入局部卷积响应进行自注意力估计, 对特征图上的每一个空间位置 (x, y) 计算其显著性权重 $A_{x,y}$, 并将其作为尺度因子重新加权原始特征图:

$$\mathbf{F}'(x, y) = A_{x,y} \cdot \mathbf{F}(x, y),$$

其中, $\mathbf{F}$ 表示原始BEV特征图, $\mathbf{F}'$ 为增强后结果;

采用自上而下的分辨率恢复机制, 将高层语义特征进行逐步上采样, 并与低层细节特征拼接融合; 融合策略用如下形式表示:

$$\mathbf{F}_l^{\text{fuse}} = \text{Concat}(\mathbf{F}_l, \text{Upsample}(\mathbf{F}_{l+1})),$$

其中, $\mathbf{F}_l$ 为当前尺度特征图, $\mathbf{F}_{l+1}$ 为上一级特征图, 拼接后再经卷积整合特征维度, 生成统一通道数的融合结果。

6. 根据权利要求1所述的一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法, 其特征在于, 步骤5具体为: 通过参数文件载入多组预设锚框模板, 每个Anchor包含长宽高三维尺寸、中心点高度以及方向角信息; 依据空中弱目标的点云实际包络尺寸, 通过对多帧实测数据的3D包围框拟合求均值得到; 采用基于3D IoU的正负样本划分机制, 对每个Anchor预测框与真实目标框GT进行体积交并比计算;

基于分距离区间的IoU下限动态调整策略, 具体如下:

$$T_{\text{pos}}(d) = \begin{cases} 0.6, & d \leq D_1 \\ 0.5, & D_1 < d \leq D_2, \\ 0.4, & d > D_2 \end{cases},$$

其中, d 为Anchor中心到雷达的空间距离, D_1, D_2 为系统中设定的分区阈值; 并对每个Anchor的中心高度进行对齐调整。

7. 根据权利要求1所述的一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法, 其特征在于, 步骤6具体为: 针对低慢小目标的空间飞行特征, 采用六维状态向量对其轨迹进行建模, 前三维表示目标在当前帧的三维空间位置, 后三维表示目标的速度分量; 设目标在短时间内满足匀速直线飞行模型, 建立状态预测模型:

$$\mathbf{x}_k = \mathbf{F}_k \cdot \mathbf{x}_{k-1} + \mathbf{w}_k,$$

其中, $\mathbf{x}_{k-1}$ 为上一时刻对目标状态向量的后验估计值, $\mathbf{F}_k$ 为状态转移矩阵, 定义为:

$$\mathbf{F}_k = \begin{bmatrix} 1 & 0 & 0 & \Delta t & 0 & 0 \\ 0 & 1 & 0 & 0 & \Delta t & 0 \\ 0 & 0 & 1 & 0 & 0 & \Delta t \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix},$$

其中, Δt 为根据激光雷达扫描频率确定的采样周期;

过程噪声 $\mathbf{w}_k$ 服从零均值高斯分布,用以吸收模型外的非线性扰动或控制误差;观测模型基于激光雷达检测结果构建,当前帧检测目标的空间坐标作为观测输入:

$$\mathbf{z}_k = \mathbf{H}_k \cdot \mathbf{x}_k + \mathbf{v}_k,$$

其中:

$$\mathbf{H}_k = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \end{bmatrix},$$

$\mathbf{v}_k$ 为观测噪声,建模检测结果的不确定性;

每当新一帧点云检测结果生成后,滤波器完成状态预测与更新:

状态预测:

$$\hat{\mathbf{x}}_{k|k-1} = \mathbf{F}_k \cdot \hat{\mathbf{x}}_{k-1|k-1},$$

$$\mathbf{P}_{k|k-1} = \mathbf{F}_k \cdot \mathbf{P}_{k-1|k-1} \cdot \mathbf{F}_k^T + \mathbf{Q}_k,$$

其中, $\hat{\mathbf{x}}_{k|k-1}$ 为在k时刻的先验状态估计值,表示根据 k-1 时刻的状态和运动模型预测出来的结果, $\hat{\mathbf{x}}_{k-1|k-1}$ 在k-1时刻的后验状态估计值,表示已经融入k-1时刻及之前的所有观测数据的最优估计, $\mathbf{P}_{k|k-1}$ 为在k时刻的先验误差协方差矩阵,表示预测状态的不确定性, $\mathbf{P}_{k-1|k-1}$ 为在k-1时刻的后验误差协方差矩阵,表示上一时刻最优估计的不确定性, $\mathbf{Q}_k$ 为过程噪声协方差矩阵,代表状态转移模型的不准确程度; $\mathbf{F}_k^T$ 为状态转移矩阵 $\mathbf{F}_k$ 的转置矩阵;

观测更新:

$$\mathbf{K}_k = \mathbf{P}_{k|k-1} \cdot \mathbf{H}_k^T \cdot (\mathbf{H}_k \cdot \mathbf{P}_{k|k-1} \cdot \mathbf{H}_k^T + \mathbf{R}_k)^{-1},$$

$$\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k \cdot (\mathbf{z}_k - \mathbf{H}_k \cdot \hat{\mathbf{x}}_{k|k-1}),$$

$$\mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k \cdot \mathbf{H}_k) \cdot \mathbf{P}_{k|k-1},$$

其中, $\mathbf{K}_k$ 为在k时刻的卡尔曼增益, $\mathbf{H}_k$ 为观测矩阵, $\mathbf{H}_k^T$ 为观测矩阵 $\mathbf{H}_k$ 的转置矩阵,将六维的状态空间映射到三维的观测空间, $\mathbf{R}_k$ 为观测噪声协方差矩阵,代表激光雷达的测量误差和不确定性, $\hat{\mathbf{x}}_{k|k}$ 为在k时刻的后验状态估计值,是经过观测更新后得到的最优、最终的状态输出, $\mathbf{P}_{k|k}$ 为在k时刻的后验误差协方差矩阵,代表最终最优估计的不确定性;

在每一帧完成EKF状态更新后,将最新估计的目标位置 (x, y, z) 转换为相对于云台原点的方位角Yaw与俯仰角Pitch,用于驱动云台实时转向:

方位角计算:

$$\theta_{\text{yaw}} = \arctan 2(y, x),$$

俯仰角计算:

$$\theta_{\text{pitch}} = \arctan 2\left(z, \sqrt{x^2 + y^2}\right).$$

8.一种计算机装置,包括存储器、处理器及存储在存储器上的计算机程序,其特征在于,所述处理器执行所述计算机程序以实现权利要求1所述方法的步骤。

9.一种计算机可读存储介质,其上存储有计算机程序/指令,其特征在于,该计算机程序/指令被处理器执行时实现权利要求1所述方法的步骤。

10.一种计算机程序产品,包括计算机程序/指令,其特征在于,该计算机程序/指令被处理器执行时实现权利要求1所述方法的步骤。

一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法

技术领域

[0001] 本发明属于控制理论和信号处理领域,尤其涉及一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法。

背景技术

[0002] 随着无人机、模型飞行器等小型飞行平台的广泛应用,以“低空、慢速、小型”(简称“低慢小”)为典型特征的新型飞行目标在城市、交通、能源、军事等领域中频繁出现。这类目标因其体积小、飞行高度低、速度慢、雷达反射特性弱、易于隐蔽等特点,在当前的空域安全管理中日益凸显其潜在威胁。特别是在城市环境中,低慢小目标可轻易绕过传统防空系统的监控,形成严重的安防隐患。因此,如何实现对低慢小目标的高精度、全天候、全时域探测与稳定跟踪,成为当前智能感知与低空安防领域的重要研究方向。

[0003] 在众多探测技术中,激光雷达(LiDAR)以其高精度、高空间分辨率、不依赖光照条件等优势,在目标三维感知与空间定位方面展现出巨大潜力。与传统的毫米波雷达相比,激光雷达能够获取高密度的点云数据,具有更强的物体轮廓还原能力,适用于复杂环境下小型目标的几何特征提取与运动轨迹跟踪。尤其在多障碍城市环境中,激光雷达能有效获取目标的空间位置信息,辅助精确判断其位置、姿态与运动状态。

[0004] 然而,激光雷达在用于低慢小目标探测时也面临一系列挑战。一方面,低慢小目标由于体积小、飞行轨迹不规则,反射激光信号弱,在点云中表现为稀疏、不连续,极易被背景地面点、建筑物反射点或树冠等干扰点所淹没,导致检测准确率不高。另一方面,受限于激光雷达的扫描频率和视场范围,当目标出现快速移动、急转变向或短时遮挡时,点云数据帧间差异大,给连续跟踪与状态预测带来显著困难。此外,低空环境中激光回波还易受多路径反射、雨雾遮挡等因素影响,进一步加剧了目标识别的复杂性。

[0005] 虽然部分研究尝试结合点云分割、特征聚类与深度学习方法来提升激光雷达对低慢小目标的探测能力,但在实际应用中仍面临不少挑战。例如,当低慢小目标反射特征弱、尺寸微小或运动轨迹复杂时,现有方法往往依赖较强的先验信息或较为理想的环境条件,难以在通用场景下保证检测与跟踪的稳定性。同时,许多现有算法主要针对地面目标(如车辆、行人)设计,在目标尺度、运动模式、空间分布等方面与空中低慢小目标存在本质差异,导致其在飞行目标场景中的泛化能力有限。

[0006] 与激光雷达相对比,传统的可见光成像系统虽然能够提供丰富的纹理和色彩信息,但在光照不稳定、逆光或夜间条件下性能急剧下降,且不具备三维空间定位能力。尤其在目标与背景颜色对比不明显的情況下,容易导致误检和漏检,并在短时遮挡或高速飞行时发生目标丢失。

[0007] 事件相机凭借其高时间分辨率和对动态目标的敏感性,可以快速响应突发移动事件,但在目标的结构与纹理特征表达方面能力有限,仅适合辅助判断目标的轨迹,不适合作为主探测手段。红外热成像适用于夜间和低能见度环境,但受限于低慢小目标热辐射弱、热对比度低等问题,在远距离目标识别中精度有限。射频与声纹探测虽然具备全天候、低成本

的优势,但在嘈杂环境中识别准确率不高,且无法提供精确的空间位置信息,难以实现高精度跟踪。

[0008] 综上所述,在复杂的城市或野外低空环境中,低慢小目标的探测与跟踪需要系统同时具备高空间分辨率、大视场覆盖能力、强抗干扰性、目标几何结构还原能力与稳定跟踪能力。而激光雷达因其具备丰富的三维空间信息和对非合作目标的感知能力,是实现该目标的重要技术路径之一。但现有激光雷达检测技术在应用于低慢小目标场景时,仍存在对稀疏目标的感知能力不足、跟踪中断频繁、识别精度不高等问题,难以支撑实战环境中对低慢小目标实施持续、可靠监控的迫切需求。

发明内容

[0009] 发明目的:本发明的目的在于提供一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法。能够在保留激光雷达高精度优势的同时,提升其对弱反射、小体积、运动不规则目标的识别能力,并具备强鲁棒性与环境适应能力,从而实现对低慢小飞行目标的稳定、精准感知与持续跟踪。

[0010] 技术方案:本发明的一种基于激光雷达的低慢小目标检测与轨迹预测跟踪方法,包括如下步骤:步骤1、采集激光雷达点云数据,并对激光雷达点云数据进行空间建模和坐标变换的预处理;

[0011] 步骤2、对预处理后的数据进行显著性筛选,得到筛选后的点云数据。

[0012] 步骤3、基于距离分区驱动,对筛选后的点云数据进行Pillar构建与编码,得到pillar表达向量。

[0013] 步骤4、构建深度学习检测网络,以pillar表达向量作为输入,输出融合后的特征。

[0014] 步骤5、基于Anchor设计与匹配策略对融合后的特征中空中弱目标进行尺寸适配。

[0015] 步骤6、基于扩展卡尔曼滤波器EKF对目标状态进行时序预测与观测更新,完成对低慢小目标检测与轨迹的预测跟踪。

[0016] 进一步的,步骤1具体为:测量雷达从安装基准面至传感器底部的垂直高度 H_0 ,记录雷达初始安装时的俯仰角 θ 、水平旋转偏转 ψ ,以及雷达相对于载体坐标系原点的水平位置偏移量 $\Delta x, \Delta y$,将数据输入标定模块,构建雷达传感器在平台坐标系下的外参矩阵 T_{ext} ;在点云采集过程中,每一帧原始点云数据以局部坐标形式表示为:

[0017] $P^{raw} = \{P_i = (x_i, y_i, z_i, I_i)\}_{i=1}^N$ 。

[0018] 其中, P^{raw} 为每一帧点云的原始数据, x, y, z 为每个点云在局部坐标系下的横坐标,纵坐标以及高度信息, I 为每个点云的反射强度, N 为每帧原始点云数据中点云的数量;读取外参 T_{ext} ,并对每个点执行坐标变换:

$$[0019] \quad P_i^{abs} = T_{ext} \cdot \begin{bmatrix} x_i \\ y_i \\ z_i \\ 1 \end{bmatrix}。$$

[0020] 变换后得到点在平台全局空间下的位置 $(x_i^{abs}, y_i^{abs}, z_i^{abs})$ 。

[0021] 计算点相对于地面的垂直高度信息: $h_i = z_i^{abs} - H_0$ 。

[0022] 对每个点计算其空间距离: $d_i = \sqrt{(x_i)^2 + (y_i)^2 + (z_i)^2}$ 。根据经验设定的阈值 D_1, D_2

, 将点云划分为三个空间区域: $Region(P_i) = \begin{cases} \text{Near Field}, & d_i \leq D_1 \\ \text{Mid Field}, & D_1 < d_i \leq D_2 \\ \text{Far Field}, & d_i > D_2 \end{cases}$ 。

[0023] 其中, $Region$ 为点云的空间区域, D_1, D_2 为根据经验设定的点云近距离, 中距离以及远距离的阈值界限。

[0024] 进一步的, 步骤2具体为: 每帧点云采集完成后, 扫描所有点的反射强度值, 提取该帧的最大值 $I_{\max}$ 与最小值 $I_{\min}$, 对每个点的反射强度 I_i 进行归一化: $\tilde{I}_i = \frac{I_i - I_{\min}}{I_{\max} - I_{\min}}$ 。

[0025] 采用KD-Tree邻域搜索在每个点的三维邻域内统计邻域点数量 $N_r(i)$: $N_r(i) = |\{P_j \in P \mid \|P_j - P_i\|_2 < r\}|$ 。

[0026] 其中, P_i 为当前正在计算显著性的目标点, P_j 为点云 P 中的其他任意点;

[0027] 将邻域点数归一化: $\tilde{N}_i = \frac{N_r(i)}{\max_j N_r(j)}$ 。

[0028] 其中, $\tilde{N}_i$ 为归一化局部密度值, $\max_j N_r(j)$ 为当前帧点云中所有点的局部密度值的最大值。

[0029] 在两个维度的归一化之后, 为每个点构建显著性评分 S_i : $S_i = \lambda_1 \cdot \tilde{I}_i + \lambda_2 \cdot \tilde{N}_i$ 。

[0030] 其中, $\lambda_1 + \lambda_2 = 1$; 引入自适应权重调整机制: 在运行时, 当某点属于Far Field区域时, 上调 λ_1 权重, 同时降低显著性阈值 T_s : $\lambda_1^{far} = \lambda_1 + \Delta_\lambda, T_s^{far} = T_s - \Delta_T$ 。

[0031] 其中, Δ_λ 和 Δ_T 表示动态基础阈值系数, T_s^{far} 表示点云处于Far Field区域的显著性阈值。最终, 依据阈值判断是否保留该点进入后续pillar构建: $Retain(P_i) = \begin{cases} 1, & S_i \geq T_s \\ 0, & S_i < T_s \end{cases}$ 。

[0032] 进一步的, 步骤3具体为: 读取pillar参数表, 采用栅格索引法进行pillar划分, 按所选区域内的 $(\Delta x, \Delta y)$ 网格划分BEV空间。

[0033] 每个格点对应一个pillar柱体, 将筛选保留的点云投影至BEV网格, 标记所属pillar编号, 若某pillar内点数 $\geq$ 该区域内对应 $n_{\min}$, 则视为合法pillar, 进入下一阶段编码, 其余点云剔除; 对每个合法pillar内的点 $\{p_j\}_{j=1}^n$, 计算点与pillar内质心的偏移量和点与pillar中心网格位置的偏移量后进行特征向量拼接, 通过共享MLP对每个点特征进行升维编码, 随后在pillar维度做最大池化, 形成定长的pillar表达向量。

[0034] 进一步的, 步骤4具体为: 在主干网络的浅层与中层特征输出中, 引入局部卷积响

应进行自注意力估计,对特征图上的每一个空间位置 (x,y) 计算其显著性权重 $A_{x,y}$,并将其作为尺度因子重新加权原始特征图: $\mathbf{F}'(x,y) = A_{x,y} \cdot \mathbf{F}(x,y)$ 。

[0035] 其中, $\mathbf{F}$ 表示原始BEV特征图, $\mathbf{F}'$ 为增强后结果。采用自上而下的分辨率恢复机制,将高层语义特征进行逐步上采样,并与低层细节特征拼接融合;融合策略用如下形式表示:

$$\mathbf{F}_l^{\text{fuse}} = \text{Concat}(\mathbf{F}_l, \text{Upsample}(\mathbf{F}_{l+1}))。$$

[0036] 其中, $\mathbf{F}_l$ 为当前尺度特征图, $\mathbf{F}_{l+1}$ 为上一级特征图,拼接后再经卷积整合特征维度,生成统一通道数的融合结果。

[0037] 进一步的,步骤5具体为:通过参数文件载入多组预设锚框模板,每个Anchor包含长宽高三维尺寸、中心点高度以及方向角信息;依据空中弱目标的点云实际包络尺寸,通过对多帧实测数据的3D包围框拟合求均值得到;采用基于3D IoU的正负样本划分机制,对每个Anchor预测框与真实目标框GT进行体积交并比计算;基于分距离区间的IoU下限动态调

$$\text{整策略,具体如下: } T_{\text{pos}}(d) = \begin{cases} 0.6, & d \leq D_1 \\ 0.5, & D_1 < d \leq D_2 \\ 0.4, & d > D_2 \end{cases}。$$

[0038] 其中, d 为Anchor中心到雷达的空间距离, D_1, D_2 为系统中设定的分区阈值;并对每个Anchor的中心高度进行对齐调整。

[0039] 进一步的,步骤6具体为:针对低慢小目标的空间飞行特征,采用六维状态向量对其轨迹进行建模,前三维表示目标在当前帧的三维空间位置,后三维表示目标的速度分量。

[0040] 设目标在短时间内满足匀速直线飞行模型,建立状态预测模型: $\mathbf{x}_k = \mathbf{F}_k \cdot \mathbf{x}_{k-1} + \mathbf{w}_k$ 。

[0041] 其中, $\mathbf{x}_{k-1}$ 为上一时刻对目标状态向量的后验估计值, $\mathbf{F}_k$ 为状态转移矩阵,定义为:

$$\mathbf{F}_k = \begin{bmatrix} 1 & 0 & 0 & \Delta t & 0 & 0 \\ 0 & 1 & 0 & 0 & \Delta t & 0 \\ 0 & 0 & 1 & 0 & 0 & \Delta t \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}。$$

[0042] 其中, Δt 为根据激光雷达扫描频率确定的采样周期。

[0043] 过程噪声 $\mathbf{w}_k$ 服从零均值高斯分布,用以吸收模型外的非线性扰动或控制误差;观测模型基于激光雷达检测结果构建,当前帧检测目标的空间坐标作为观测输入:

$$\mathbf{z}_k = \mathbf{H}_k \cdot \mathbf{x}_k + \mathbf{v}_k。$$

$$\text{[0044] 其中: } \mathbf{H}_k = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \end{bmatrix}, \mathbf{v}_k \text{ 为观测噪声,建模检测结果的不确定性。}$$

[0045] 每当新一帧点云检测结果生成后,滤波器完成状态预测与更新:状态预测:

$$\hat{\mathbf{x}}_{k|k-1} = \mathbf{F}_k \cdot \hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k|k-1} = \mathbf{F}_k \cdot \mathbf{P}_{k-1|k-1} \cdot \mathbf{F}_k^T + \mathbf{Q}_k。$$

[0046] 其中, $\hat{\mathbf{x}}_{k|k-1}$ 为在k时刻的先验状态估计值,表示根据 k-1 时刻的状态和运动模型预测出来的结果, $\hat{\mathbf{x}}_{k-1|k-1}$ 在k-1时刻的后验状态估计值,表示已经融入k-1时刻及之前的所有观测数据的最优估计, $\mathbf{P}_{k|k-1}$ 为在k时刻的先验误差协方差矩阵,表示预测状态的不确定性, $\mathbf{P}_{k-1|k-1}$ 为在k-1时刻的后验误差协方差矩阵,表示上一时刻最优估计的不确定性, $\mathbf{Q}_k$ 为过程噪声协方差矩阵,代表状态转移模型的不准确程度; $\mathbf{F}_k^T$ 为状态转移矩阵 $\mathbf{F}_k$ 的转置矩阵。

$$[0047] \quad \text{观测更新: } \mathbf{K}_k = \mathbf{P}_{k|k-1} \cdot \mathbf{H}_k^T \cdot (\mathbf{H}_k \cdot \mathbf{P}_{k|k-1} \cdot \mathbf{H}_k^T + \mathbf{R}_k)^{-1}。$$

$$[0048] \quad \hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k \cdot (\mathbf{z}_k - \mathbf{H}_k \cdot \hat{\mathbf{x}}_{k|k-1})。$$

$$[0049] \quad \mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k \cdot \mathbf{H}_k) \cdot \mathbf{P}_{k|k-1}。$$

[0050] 其中, $\mathbf{K}_k$ 为在k时刻的卡尔曼增益, $\mathbf{H}_k$ 为观测矩阵, $\mathbf{H}_k^T$ 为观测矩阵 $\mathbf{H}_k$ 的转置矩阵,将六维的状态空间映射到三维的观测空间, $\mathbf{R}_k$ 为观测噪声协方差矩阵,代表激光雷达的测量误差和不确定性, $\hat{\mathbf{x}}_{k|k}$ 为在k时刻的后验状态估计值,是经过观测更新后得到的最优、最终的状态输出, $\mathbf{P}_{k|k}$ 为在k时刻的后验误差协方差矩阵,代表最终最优估计的不确定性。

[0051] 在每一帧完成EKF状态更新后,将最新估计的目标位置 (x, y, z) 转换为相对于云台原点的方位角Yaw与俯仰角Pitch,用于驱动云台实时转向:方位角计算: $\theta_{\text{yaw}} = \arctan 2(y, x)$ 。

$$[0052] \quad \text{俯仰角计算: } \theta_{\text{pitch}} = \arctan 2\left(z, \sqrt{x^2 + y^2}\right)。$$

[0053] 本发明还公开一种计算机装置,包括存储器、处理器及存储在存储器上的计算机程序,所述处理器执行所述计算机程序以实现本发明方法的步骤。

[0054] 本发明还公开一种计算机可读存储介质,其上存储有计算机程序/指令,该计算机程序/指令被处理器执行时实现本发明方法的步骤。

[0055] 本发明还公开一种计算机程序产品,包括计算机程序/指令,该计算机程序/指令被处理器执行时实现本发明方法的步骤。

[0056] 有益效果:与现有技术相比,本发明具有如下显著优点:1、激光雷达点云采集与预处理方面:本发明针对低慢小目标雷达散射截面积小、反射信号弱等特点,设计了适用于小型空中目标的点云预处理策略,提升了低信噪比背景下的目标点云显著性。在数据采集与滤波阶段增强对微弱回波的保留能力,同时抑制地面杂波、树木、建筑物等背景干扰点,从而为后续识别模型提供更清晰、稳定的点云输入。

[0057] 2、深度学习模型设计方面:本发明在深度学习网络结构上进行了定制优化,将主流基于地面目标(如汽车、行人)的三维检测模型调整为适用于空中低慢小飞行目标的结构。模型在体积尺度适配、特征提取层级、检测框架尺度匹配等方面进行了专门设计,以更好地适配目标尺寸小、形状不规则、点云稀疏等特点,从而提高检测精度与鲁棒性。

[0058] 3、扩展卡尔曼滤波跟踪预测方面:考虑到低慢小目标的运动轨迹易变、姿态不稳

定等特性,本发明引入扩展卡尔曼滤波算法对检测结果进行状态估计与轨迹预测。该方法结合激光雷达多帧点云数据与目标动态模型,实时更新目标的空间位置、速度和加速度等状态变量,有效解决短时遮挡、检测抖动、临时漏检等问题,提升跟踪连续性与预测准确性。

[0059] 4、本发明构建了一种面向低慢小飞行目标的激光雷达感知与跟踪系统,具备良好的目标检测精度、跟踪稳定性与环境适应能力,能够为低空安全监测、无人机管控等应用场景提供有效技术支撑。

附图说明

[0060] 图1为本发明的流程图。

具体实施方式

[0061] 下面结合附图对本发明的技术方案作进一步说明。

[0062] 本发明针对低慢小飞行目标在点云数据中的特性,结合PointPillars模型的数据输入要求,设计了包括高频率激光雷达采集、数据空间规整、特征增强、背景去除及体素化构建等多个子模块的点云预处理框架,从而在数据输入层实现对低慢小目标的高效提取与结构表达。如图1所示,本发明的技术方案包括以下主要步骤:步骤1:激光雷达点云采集与距离感知预处理。

[0063] 1.1距离感知的点云区域建模:本发明所使用的激光雷达设备固定安装于具备俯仰旋转能力的双自由度云台上,为后续空间建模与目标定位提供了动态感知能力。为保证系统对点云三维结构的准确解读,需在设备部署初期完成雷达安装位置的测量与空间参数配置。具体操作如下:首先,使用卷尺等测量工具,精确测量雷达从安装基准面(如平台地面)至传感器底部的垂直高度,记为安装高度 H_0 ,单位为米。同时,借助水平仪和测角器等仪器,记录雷达初始安装时的俯仰角(Pitch Angle) θ 、水平旋转偏转(Yaw) ψ ,以及相对于载体坐标系原点的水平位置偏移量 $\Delta x, \Delta y$ 。

[0064] 完成上述测量后,将上述数据输入标定模块,构建雷达传感器在平台坐标系下的外参矩阵 T_{ext} 。该矩阵以四维齐次坐标变换的形式存储,并写入系统配置文件,供运行时实时调用。在点云采集过程中,每一帧原始点云数据以局部坐标形式表示为:

$$P^{raw} = \{P_i = (x_i, y_i, z_i, 1)\}_{i=1}^N。$$

[0065] 为将其转换至绝对坐标系,系统在数据预处理阶段读取外参 T_{ext} ,并对每个点执行

$$\text{坐标变换: } P_i^{abs} = T_{ext} \cdot \begin{bmatrix} x_i \\ y_i \\ z_i \\ 1 \end{bmatrix}。$$

[0066] 变换后得到点在平台全局空间下的位置 $(x_i^{abs}, y_i^{abs}, z_i^{abs})$,用于后续高度计算与空间筛选。

[0067] 为了进一步识别低空飞行目标的潜在点云特征,计算点相对于地面的垂直高度信

息: $h_i = z_i^{\text{abs}} - H_0$ 。

[0068] 该高度将作为后续显著性评分与分类判断的输入维度之一,用于判别目标是否可能属于低慢小飞行器。与此同时,对每个点计算其空间距离(即其到雷达中心的三维欧氏距离): $d_i = \sqrt{(x_i)^2 + (y_i)^2 + (z_i)^2}$ 。根据经验设定的阈值 D_1, D_2 ,将点云划分为三个空间区域:

$$\text{Region}(P_i) = \begin{cases} \text{Near Field}, & d_i \leq D_1 \\ \text{Mid Field}, & D_1 < d_i \leq D_2 \\ \text{Far Field}, & d_i > D_2 \end{cases}$$

[0069] 该区域信息将贯穿后续显著性筛选与pillar构建流程,作为距离感知自适应处理的重要依据。

[0070] 1.2自适应显著性筛选机制:在实际任务中,激光雷达采集的点云数据中混杂了大量非目标点,如地面、建筑边缘和背景植被等杂散回波,尤其在远距离区域,目标点往往只有极少数稀疏点存在,极易被误滤或淹没。因此,在体素化编码之前,对点云进行合理筛选显得尤为关键。

[0071] 为此,本发明设计了融合“反射特性”和“局部几何结构”的显著性打分机制,目的在于优先保留可能属于目标物体的关键点,尤其是对远距离小目标的稀疏点给予额外保留机会。

[0072] (1)反射强度归一化:每帧点云采集完成后,系统首先扫描所有点的反射强度值,提取该帧的最大值 $I_{\max}$ 与最小值 $I_{\min}$ 。随后对每个点的反射强度 I_i 进行归一化:

$$\tilde{I} = \frac{I_i - I_{\min}}{I_{\max} - I_{\min}}。$$

[0073] 这一处理统一了不同帧之间的强度范围差异,增强了评分机制的稳定性。

[0074] (2)局部密度估计:在每个点的三维邻域(球半径 r)内统计邻域点数量 $N_r(i)$ 。采用KD-Tree快速邻域搜索实现,计算效率高,适用于大规模点云:

[0075] $N_r(i) = |\{P_j \in P \mid \|P_j - P_i\|_2 < r\}|$,为便于不同点之间的比较,将邻域点数归一化:

$$\tilde{N}_i = \frac{N_r(i)}{\max_j N_r(j)}。$$

[0076] 该密度值反映了点所处局部的几何结构复杂度,高密度点通常属于结构清晰的目标或其边界区域。

[0077] (3)显著性打分与自适应增强机制:在完成上述两个维度的归一化之后,为每个点构建显著性评分: $S_i = \lambda_1 \cdot \tilde{I}_i + \lambda_2 \cdot \tilde{N}_i$ 。

[0078] 其中, $\lambda_1 + \lambda_2 = 1$ 。在系统配置中,该参数组可由用户指定,例如默认值为 $\lambda_1 = 0.4$ 、 $\lambda_2 = 0.6$ 。

[0079] 为了提升远距离稀疏目标的保留能力,本发明引入了“自适应权重调整”机制:在运行时,当某点属于“Far Field”区域时,系统将自动上调 λ_1 权重(提升对反射强度的重

视),同时降低显著性阈值 T_s ,例如: $\lambda_1^{far} = \lambda_1 + \Delta_\lambda, T_s^{far} = T_s - \Delta_T$ 。

[0080] 其中 Δ_λ 和 Δ_T 通过实测数据优化设定,系统根据检测目标的距离分布动态调参,确保远距离稀疏点更容易通过筛选。最终,依据阈值判断是否保留该点进入后续pillar构建:

$$\text{Retain}(P_i) = \begin{cases} 1, & S_i \geq T_s \\ 0, & S_i < T_s \end{cases}。$$

[0081] 1.3距离分区驱动的Pillar构建与编码策略:在激光雷达三维目标检测任务中,PointPillars编码结构通过将空间点云映射为二维Bird's Eye View (BEV) 平面,有效提升了特征处理效率。然而,在面对低慢小飞行目标时,尤其是其出现在远距离区域、点云稀疏时,传统统一尺寸体素划分策略往往出现以下问题:远距离区域:点数稀疏、分布零散,体素内点不足,难以成柱。

[0082] 近距离区域:点数密集但pillar分辨率过低,导致边界细节丢失。

[0083] 统一参数策略:无法兼顾不同距离目标的特征表达需要。

[0084] 为解决这些问题,本发明提出了一种基于距离感知的自适应pillar构建机制,核心理想为“按距离区域动态设置pillar结构参数”,以增强pillar生成的普适性和有效性。

[0085] (1) 区域分类与参数加载:本模块在系统启动时,自动读取配置文件中预设的pillar 参数表,如表1所示。

表 1

	区域	Bev 体素边长 ($\Delta x, \Delta y, \Delta z$)	最小 pillar 点数 $n_{\min}$
[0086]	Near Field	(0.10m,0.10m,0.20m)	5
	Mid Field	(0.16m,0.16m,0.40m)	4
	Far Field	(0.25m,0.25m,0.60m)	2

[0087] 这些参数值基于大量飞行实测点云进行调优,针对不同距离下目标的点数特征和结构分布特点设定。

[0088] 在每帧处理时,系统依据先前计算的 d_i 值(即点的空间距离),为每个点赋予区域标签(近、中、远),并据此采用不同的pillar划分参数。

[0089] (2) pillar生成操作流程:本模块采用栅格索引法进行pillar划分,按所选区域内的 $(\Delta x, \Delta y)$ 网格划分BEV空间;每个格点对应一个pillar柱体,将筛选保留的点云投影至BEV网格,标记所属pillar编号,若某pillar内点数 $\geq$ 该区域内对应 $n_{\min}$,则视为合法pillar,进入下一阶段编码,其余点云剔除或缓存供全局优化使用。

[0090] (3) 特征编码方式:对每个合法pillar内的点 $\{p_j\}_{j=1}^n$,系统依次计算以下几类局部

$$\bar{x}_k = \frac{1}{n} \sum_{j=1}^n x_j, \quad \Delta x_j = x_j - \bar{x}_k$$

特征:点与pillar内质心的偏移量: $\bar{y}_k = \frac{1}{n} \sum_{j=1}^n y_j, \quad \Delta y_j = y_j - \bar{y}_k$ 。

$$\bar{z}_k = \frac{1}{n} \sum_{j=1}^n z_j, \quad \Delta z_j = z_j - \bar{z}_k$$

[0091] 点与pillar中心网格位置的偏移量: $x_j^c = x_j - x_c, \quad y_j^c = y_j - y_c$ 。

[0092] 其中 (x_c, y_c) 为该pillar中心在BEV平面中的坐标。

[0093] 完整点特征向量拼接: $\mathbf{f}_j = [\Delta x_j, \Delta y_j, \Delta z_j, x_j^c, y_j^c, I_j]$ 。

[0094] 特征编码:通过共享MLP对每个点特征进行升维编码,随后在pillar维度做最大池化,形成定长的pillar表达向量。

[0095] 最终所有pillar编码结果组成稀疏张量输入,交由主干网络进行空间感知与目标检测。

[0096] 步骤2:基于多尺度结构的检测网络设计与增强模块机制:本发明基于前述稀疏BEV编码结果构建了一种多尺度感知主干网络,并在关键层级嵌入空间增强机制与通道注意机制,以显著提升检测的鲁棒性和灵敏性。

[0097] 2.1多尺度金字塔结构主干网络:点云检测场景中,低慢小目标在不同距离下的体积尺度变化显著:近距离区域体素密集,目标特征清晰,易于捕捉边缘与几何形状;而远距离区域点数稀疏、目标轮廓模糊,特征表达受限,易被背景掩盖。

[0098] 为适配这种分布特性,本发明构建的BEV主干网络采用金字塔式结构展开特征提取通路,由多个下采样层级依次构建,不同尺度的特征层具有不同的感受野:

[0099] 第1层保持原始BEV尺寸,侧重保留小目标的空间细节;第2层通过2倍下采样扩展感受野,捕捉中尺度结构;第3层进一步下采样,获取大范围背景与上下文信息。

[0100] 每一层采用卷积层组合堆叠构建,通道数依网络深度自下而上逐步增加,用于增强语义表达能力。各层输出的特征图将在后续融合模块中进行级联或上采样汇聚,实现信息回流,兼顾多尺度结构表征。

[0101] 2.2 空间注意力与边缘引导增强机制:在处理稀疏点云特征时,目标本身结构信息较弱,因此需引入空间维度上的关注机制以突出潜在目标区域,抑制背景干扰。本发明设计了一种空间增强子模块,对BEV特征图施加空间权重调节,从而动态增强结构敏感区域。

[0102] 在主干网络的浅层与中层特征输出中,引入局部卷积响应进行自注意力估计,对特征图上的每一个空间位置 (x, y) 计算其显著性权重 $A_{x,y}$,并将其作为尺度因子重新加权原始特征图: $\mathbf{F}'(x, y) = A_{x,y} \cdot \mathbf{F}(x, y)$ 。

[0103] 其中, $\mathbf{F}$ 表示原始BEV特征图, $\mathbf{F}'$ 为增强后结果。该机制在远距离区域对稀疏特征响应尤为明显,可突出弱目标的轮廓形态。

[0104] 此外,考虑到小目标多分布在背景边缘位置,在BEV平面中利用局部梯度信息构建边界响应图,引导特征聚焦于边缘细节,从而提升微小结构的保持能力。

[0105] 2.3 特征融合与分辨率回流策略:为解决多尺度特征间上下语义不一致的问题,采用自上而下的分辨率恢复机制,将高层语义特征进行逐步上采样,并与低层细节特征拼接融合。

[0106] 该融合策略可用如下形式表示: $\mathbf{F}_i^{\text{fuse}} = \text{Concat}(\mathbf{F}_i, \text{Upsample}(\mathbf{F}_{i+1}))$ 。

[0107] 其中, $\mathbf{F}_i$ 为当前尺度特征图, $\mathbf{F}_{i+1}$ 为上一级(低分辨率)特征图,拼接后再经卷积整合特征维度,生成统一通道数的融合结果。通过逐级向上融合,系统在最终检测头输入前获得了兼具细节与上下文的多尺度特征表达。

[0108] 步骤3:基于空中弱目标的Anchor设计与匹配策略:在BEV表示的点云目标检测中,锚框(Anchor)机制是建立预测与真实目标关联的基础,其匹配质量直接影响后续检测网络的回归精度与正负样本平衡。传统anchor设计多基于固定尺寸且偏向大目标的车辆/行人任务,对于低慢小飞行器这类空域弱目标,存在匹配率低、正样本不足、定位误差大的问题。

[0109] 本发明面向空域飞行微目标特性,重新设计锚框尺寸体系,并在匹配机制中引入距离分区调节策略与IoU动态下限调整机制,全面提升弱目标的锚框匹配率与训练样本质量。

[0110] 3.1Anchor几何参数设计与预配置:为覆盖多种尺度飞行目标(如微型无人机、遥控滑翔机等)的外形特征,本发明在检测网络初始化阶段,通过参数文件载入多组预设锚框模板。每个Anchor包含长宽高三维尺寸、中心点高度以及方向角信息。锚框模板样式如表2所示。

表 2

Anchor	长 l	宽 w	高 h	中心高度 z_c	方向角 (rad)
Type-A	0.3m	0.3m	0.4m	0.6m	$0, \frac{\pi}{2}$
Type-B	0.6m	0.8m	0.6m	0.8m	$0, \frac{\pi}{2}$
Type-C	1.2m	1.6m	1.0m	1.0m	$0, \frac{\pi}{2}$

[0112] 锚框设计过程中,依据空中弱目标的点云实际包络尺寸,通过对多帧实测数据的3D包围框拟合求均值得到。同时对每类Anchor分别配置多个朝向角度,以提升对多方向飞行目标的匹配灵活性。

[0113] 3.2Anchor匹配机制与IoU下限调节:为提升Anchor匹配效率,系统采用基于3D IoU的正负样本划分机制。对每个Anchor预测框与真实目标框(Ground Truth, GT)进行体

积交并比计算: $\text{IoU}_{3D}(A_i, G_j) = \frac{\text{Vol}(A_i \cap G_j)}{\text{Vol}(A_i \cup G_j)}$ 。

[0114] 传统匹配机制常设定固定的IoU阈值(如正样本阈值0.6,负样本阈值0.3),但这在远距离目标稀疏点场景中表现不佳,因弱目标点云包络模糊、锚框与GT中心易发生偏移,导致大量有效Anchor被误判为负样本。为此,本发明提出分距离区间的IoU下限动态调整策

略,具体如下: $T_{\text{pos}}(d) = \begin{cases} 0.6, & d \leq D_1 \\ 0.5, & D_1 < d \leq D_2 \\ 0.4, & d > D_2 \end{cases}$ 。

[0115] 其中, d 为Anchor中心到雷达的空间距离, D_1, D_2 为系统中设定的分区阈值。该机制使得远距离稀疏目标能够更容易匹配到合适Anchor,提升训练过程中正样本数量,减少检测盲区。

[0116] 3.3空中目标中心高度对齐策略:低慢小目标在飞行状态下,中心高度普遍高于地面静态目标。为避免Anchor高度与目标中心不匹配带来的检测偏差,系统在匹配阶段对每个Anchor的 z_c 进行中心对齐调整:对于GT中心高度 z_g ,选择与其 z_c 最接近的Anchor作为优选。

[0117] 若匹配Anchor与GT中心高度差超出阈值(如 $\pm 0.3\text{m}$),则不予匹配,视为结构不适配。

[0118] 这种高度对齐策略可显著提升Anchor在z轴方向上的匹配稳定性,对三维检测精度有重要贡献。

[0119] 3.4锚框平衡与训练样本构建:为防止类别失衡,本发明在构建正负样本时采用以下策略:对每个GT框,至少保证一个Anchor匹配成功;对于重叠率接近阈值的Anchor,保留靠近中心的优先;控制每帧正负样本比在合理范围内(如1:3)以平衡损失计算。

[0120] 构建完成后,所有正样本将参与回归损失与分类损失计算,并通过误差反传优化网络参数。

[0121] 步骤4:基于激光雷达点云的低慢小目标轨迹关联与扩展卡尔曼滤波跟踪方法:系统采用扩展卡尔曼滤波器(EKF)对目标状态进行时序预测与观测更新,同时将估计得到的目标三维空间位置用于驱动二自由度云台转向,形成“检测-预测-转向”闭环,确保对无人机目标的持续跟踪与稳定指向。

[0122] 4.1状态建模与目标表示:针对低慢小目标的空间飞行特征,系统采用六维状态向量对其轨迹进行建模: $\mathbf{x}_k = [x_k, y_k, z_k, v_{x,k}, v_{y,k}, v_{z,k}]^T$ 。

[0123] 其中,前三维表示目标在当前帧的三维空间位置,后三维表示目标的速度分量。该状态向量能够准确表达目标在雷达坐标系中的动态行为,支持对目标运动趋势的预测。

[0124] 在系统初始化阶段,当检测模块连续多帧稳定检测到某一潜在目标,系统将建立该目标对应的 EKF 轨迹对象,并初始化其状态向量与协方差矩阵。

[0125] 4.2状态转移与观测模型:本发明假设目标在短时间内满足匀速直线飞行模型,建立状态预测模型: $\mathbf{x}_k = \mathbf{F}_k \cdot \mathbf{x}_{k-1} + \mathbf{w}_k$ 。

[0126] 其中, $\mathbf{F}_k$ 为状态转移矩阵,定义为: $\mathbf{F}_k = \begin{bmatrix} 1 & 0 & 0 & \Delta t & 0 & 0 \\ 0 & 1 & 0 & 0 & \Delta t & 0 \\ 0 & 0 & 1 & 0 & 0 & \Delta t \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$ 。

[0127] 过程噪声 $\mathbf{w}_k$ 服从零均值高斯分布,用以吸收模型外的非线性扰动或控制误差。

[0128] 与此同时,观测模型基于激光雷达检测结果构建,当前帧检测目标的空间坐标作为观测输入: $\mathbf{z}_k = \mathbf{H}_k \cdot \mathbf{x}_k + \mathbf{v}_k$ 。

[0129] 其中: $\mathbf{H}_k = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \end{bmatrix}$ 。

[0130] $\mathbf{v}_k$ 为观测噪声,建模检测结果的不确定性。

[0131] 4.3 滤波器运行流程与轨迹预测更新:在系统运行过程中,每当新一帧点云检测结果生成后,滤波器按照以下步骤完成状态预测与更新。

[0132] (1) 状态预测: $\hat{\mathbf{x}}_{k|k-1} = \mathbf{F}_k \cdot \hat{\mathbf{x}}_{k-1|k-1}$, $\mathbf{P}_{k|k-1} = \mathbf{F}_k \cdot \mathbf{P}_{k-1|k-1} \cdot \mathbf{F}_k^T + \mathbf{Q}_k$ 。

[0133] (2) 观测更新: $\mathbf{K}_k = \mathbf{P}_{k|k-1} \cdot \mathbf{H}_k^T \cdot (\mathbf{H}_k \cdot \mathbf{P}_{k|k-1} \cdot \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$ 。

[0134] $\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k \cdot (\mathbf{z}_k - \mathbf{H}_k \cdot \hat{\mathbf{x}}_{k|k-1})$ 。

[0135] $\mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k \cdot \mathbf{H}_k) \cdot \mathbf{P}_{k|k-1}$ 。

[0136] 通过上述预测与更新过程,系统可实现对目标三维空间位置与速度的连续估计,缓解短时检测漏帧、误检或遮挡所带来的轨迹不稳定问题。

[0137] 4.4 云台控制与目标跟踪驱动机制:系统在每一帧完成EKF状态更新后,将最新估计的目标位置 (x, y, z) 转换为相对于云台原点的方位角(Yaw)与俯仰角(Pitch),用于驱动云台实时转向。

[0138] 方位角计算: $\theta_{\text{yaw}} = \arctan 2(y, x)$ 。

[0139] 俯仰角计算: $\theta_{\text{pitch}} = \arctan 2\left(z, \sqrt{x^2 + y^2}\right)$ 。

[0140] 系统将上述角度值转换为 PWM 信号或电机控制指令,传输至控制板(如STM32或Jetson平台),由其驱动两个舵机控制云台的水平与垂直转动,使激光雷达朝向目标位置,保持持续跟踪状态。

[0141] 当目标在视场边缘附近移动或出现短时遮挡时,系统仍可根据 EKF 预测值进行云台转向,维持跟踪方向,提升抗干扰性与响应性。

[0142] 实施例

[0143] 首先,利用镭神智能激光雷达以10Hz频率旋转扫描来接收原始数据,每一帧数据包含数万个三维点云,每个点的信息为数据向量 $[x_i, y_i, z_i, I_i]$,根据标定好的外参矩阵 T_{ext} ,将每个点的局部坐标转换到全局坐标系下,得到点在全局空间下的位置 $(x_i^{\text{abs}}, y_i^{\text{abs}}, z_i^{\text{abs}})$,计算每个点的空间距离 d_i ,扫描全帧点云,提取该帧的最大/最小反射强度,归一化为 $\tilde{I}_i$,利用KD-Tree统计邻域点数量,计算局部点的密度,计算显著性评分,依据阈值判断是否保留该点进去后续pillar构建;将筛选后的点投影到BEV平面,根据自适应机制检测目标点所在区域,并加载相应的网格参数,计算该点与Pillar内所有点质心的偏移量和网格中心位置的

偏移量,将原始坐标与反射强度以及两个偏移量拼接成一个6维特征向量 $[\Delta x_j, \Delta y_j, \Delta z_j, x_j^c, y_j^c, I_j]$;将Pillar内所有点的特征向量输入一个共享的MLP,将每个点升维到128维,并进行Max Pooling,取出128个通道上的最大值,将处理后的Pillar特征根据其空间位置,散射回BEV网格,形成一个 $H \times W \times 128$ 的伪图像;伪图像输入一个金字塔CNN,输出多尺度特征图,将高层特征上采样与底层特征拼接,得到融合了细节和语义的最终特征图;在最终特征图上使用预设的Anchor进行分类和回归,判断每个Anchor框内是“背景”还是“低慢小目标”最终将检测出的小目标信息的前三维数据 $[x, y, z]$ 输入给卡尔曼滤波;根据观测协方差矩阵 $\mathbf{P}_{k|k-1}$ 和观测噪声 $\mathbf{R}_k$ 来计算得出卡尔曼增益,通过状态更新,修正预测量,输出轨迹预测的最优估计 $\hat{\mathbf{x}}_{k|k}$;最后将预测得到的目标位置转换为相对于云台原点的方位角和俯仰角,通过电机带动云台实现实时跟踪低慢小目标的目的。




图1